**TECHNOLOGICAL UNIVERSITY OF THE PHILIPPINES – TAGUIG**
Km. 14 East Service Road, Western Bicutan, Taguig City

**Group 5:** **June 27, 2026**

**Celetaria, Flint Axl** **WEEK #11**

**Lacorte, Krsmur Chelvin**

**Manalo, Jett Axel**

**Marbella, Sharwin John M.**

**SLIDE 1:**
**TOPIC:**

Chapter 5: Data Mining

**INSIGHTS:**

This is only the title slide of the presentation.

**SLIDE 2:**
**TOPIC:**

Members:

- Celetaria, Flint Axl
- Lacorte, Krsmur Chelvin
- Manalo, Jett Axel
- Marbella, Sharwin John M.

**INSIGHTS:**

This is only the slide that contains the names of all the members of group 5.

**SLIDE 3:**
**TOPIC:**

**Introduction**

Data mining is the process of discovering meaningful patterns, trends, and relationships from large sets of data using techniques from statistics, machine learning, and databases. It involves analyzing raw data to extract useful information that can support decision-making and predict future outcomes. Organizations use data mining to gain insights from their data, such as identifying customer behavior, detecting fraud, improving marketing strategies, and optimizing operations. As data continues to grow rapidly in the digital age, data mining plays an essential role in turning information into knowledge.

## INSIGHTS:

Good day everyone! Ang topic ko namin ngayon is about Data Mining.

So, una sa lahat, ano nga ba ang data mining?

Ang data mining ay isa siyang process kung saan kinukuha o dini-discover natin yung mga importanteng patterns, trends, at relationships galing sa napakaraming data. In other words, isipin niyo na lang na parang naghahanap tayo ng valuable information sa isang napakalaking collection ng data. Hindi lang siya basta pagtingin ng data, parang ina-analyze talaga nito para makakuha ng useful insights.

Para magawa ‘to, gumagamit ang data mining ng iba't ibang techniques tulad ng statistics, machine learning, at databases. Ang statistics ang tumutulong para ma-analyze ang mga numbers at makita ang patterns. Ang machine learning naman ay gumagamit ng AI para matuto mula sa data at makapag-predict ng mga possible na mangyari. Samantalang ang databases naman ang nagsisilbing storage kung saan naka-save ang napakaraming impormasyon.

Ang goal ng data mining ay gawing useful ung mga raw data. Kasi kung iisipin natin, napakaraming data ang nage-generate araw-araw mula sa social media, online shopping, mobile apps, at iba pang digital platforms. Pero kung hindi ito maa-analyze, parang collection lang siya ng impormasyon na walang silbi. Kaya sa pamamagitan ng data mining, nagiging knowledge ang data na pwedeng gamitin sa paggawa ng mas magandang decisions.

Maraming organizations at companies ung gumagamit ng data mining. For example, sa mga online shopping apps tulad ng Lazada o Shopee, napapansin niyo siguro na may lumalabas na recommended products. Hindi lang iyon random. Ginagamit nila ung data mining para pag-aralan kung ano ang madalas mong tignan o bilhin, tapos doon sila nagbibigay ng recommendations.

Isa pang example ay sa mga bangko. Ginagamit nila ang data mining para ma-detect ung mga unusual transactions na maaaring fraudulent o scam. Halimbawa, kung biglang may malaking withdrawal sa account mo sa ibang bansa kahit nasa Pilipinas ka lang, maaaring ma-detect agad iyon ng system at ma-alert ang bangko.

Ginagamit din ung data mining sa marketing. Dahil alam nila ang preferences at behavior ng customers, mas nakakagawa sila ng tamang advertisements para sa tamang audience. Mas nagiging effective ang kanilang marketing strategies dahil mas naiintindihan nila ang gusto ng mga customers.

Bukod pa doon, nakakatulong din ung data mining sa pag-optimize ng operations ng isang kumpanya. Like, natutulungan silang malaman kung anong products ang mabilis maubos, kung kailan dapat mag-restock, o kung paano nila mapapabilis ang kanilang serbisyo.

Sa panahon ngayon na sobrang bilis dumami ng digital data, mas lalo pang nagiging mahalaga ung data mining. Hindi sapat na marami lang tayong data. Ang mas importante ay kung paano natin ‘to gagamitin para makakuha ng useful information at makagawa ng better decisions.

So, overall, ang data mining ay ang proseso ng pagkuha ng meaningful information mula sa malaking amount ng data gamit ang iba't ibang techniques tulad ng statistics, machine learning, at

databases. Nakakatulong ‘to sa businesses at organizations para maintindihan ang kanilang data, makapag-predict ng future outcomes, makaiwas sa fraud, mapaganda ang marketing strategies, at mapabuti ang overall operations.

**SLIDE 4:**
**TOPIC:**

**CORE CONCEPTS**

- Data Mining vs. Traditional Statistics
- Supervised vs. Unsupervised Learning
- Classification, Regression, Clustering

**INSIGHTS:**

This is only the slide containing the core concepts and three of its subtopics.

**SLIDE 5:**
**TOPIC:**

Data Mining vs. Traditional Statistics

**INSIGHTS:**

This slide only shows the first subtopic of the core concepts.

**SLIDE 6:**
**TOPIC:**

**Aspect**

**1.Purpose:**

**Data Mining** - Discovers hidden patterns and makes predictions from large datasets within Data Science.

**Traditional Statistics** -Tests hypotheses and validates relationships based on existing theories.

**2.Approach:**

**Data Mining** -Uses a data-driven approach that explores data automatically with help from Machine Learning.

**Traditional Statistics** -Uses a theory-driven approach that starts with a hypothesis and applies mathematical models.

**3.Data Size and Complexity:**

**Data Mining** -Handles large, complex, and unstructured datasets from multiple sources.

**Traditional Statistics** -Works with smaller, structured, and well-organized datasets.

**4.Techniques Used:**

**Data Mining** -Applies methods like classification, clustering, and decision trees to find patterns.

**Traditional Statistics** -Uses techniques such as regression analysis and hypothesis testing to measure relationships.

**5.Output:**

**Data Mining** -Produces patterns, trends, and predictive models for decision-making.

**Traditional Statistics** -Produces statistical results like p-values and confidence intervals for interpretation.

## INSIGHTS:

So, ngayong alam na natin kung ano ang data mining, pag-usapan naman natin ang pagkakaiba ng Data Mining at Traditional Statistics.

Unang aspect ay ang Purpose o layunin. Sa Data Mining, ang main goal nito ay mag-discover ng mga hidden patterns o impormasyon na hindi agad napapansin sa napakaraming data. Hindi lang siya naghahanap ng patterns, kundi ginagamit din ito para makagawa ng predictions o forecast kung ano ang posibleng mangyari sa future. Kaya madalas itong ginagamit sa Data Science at Artificial Intelligence.

Samantala, sa Traditional Statistics, iba naman ang focus nito. Ang goal niya ay mag-test ng hypothesis o patunayan kung may relationship ba talaga ang mga variables base sa existing theories. Halimbawa, gusto mong malaman kung may epekto ba ang study hours sa grades ng students. Gumagamit ng statistical tests para malaman kung totoo ba ang assumption.

Pangalawang aspect naman ay ang Approach o paraan ng pag-aanalyze.
Sa Data Mining, data-driven ang approach. Ibig sabihin, hinahayaan muna nating magsalita ang data. Hindi kailangan na may hypothesis agad. Ang system mismo ang naghahanap ng patterns gamit ang iba't ibang techniques, lalo na ang Machine Learning.

Sa Traditional Statistics naman, theory-driven ang approach. Dito, nagsisimula muna tayo sa isang hypothesis o assumption. Pagkatapos, gumagamit tayo ng mathematical formulas at statistical methods para i-check kung tama o mali ang hypothesis natin.

Pangatlong aspect ay ang Data Size and Complexity.Ang Data Mining ay ginawa talaga para mag-handle ng malalaki at komplikadong datasets. Hindi lang numbers ang kaya nitong i-process. Pati text, images, videos, at iba pang unstructured data, kaya nitong i-analyze. Kaya bagay ito sa mga

companies na may milyon-milyong records gaya ng social media platforms at online shopping websites.

Sa kabilang banda, ang Traditional Statistics ay mas bagay sa smaller at well-organized datasets. Kadalasan, structured na ang data bago ito i-analyze. Mas simple ang setup nito kumpara sa data mining.

Pang-apat ay ang Techniques Used o mga ginagamit na methods.Sa Data Mining, gumagamit ito ng iba't ibang techniques tulad ng classification, clustering, at decision trees. Ang classification ay ginagamit para i-group ang data sa tamang category. Ang clustering naman ay naggo-group ng magkakaparehong data kahit wala pang labels. At ang decision tree naman ay tumutulong sa paggawa ng predictions o decisions base sa iba't ibang conditions.

Samantala, sa Traditional Statistics, mas common ang paggamit ng regression analysis at hypothesis testing. Ang regression ay ginagamit para malaman kung may relationship ang dalawang variables, habang ang hypothesis testing naman ay ginagamit para malaman kung statistically significant ba ang resulta.

At ang huling aspect ay ang Output o resulta. Sa Data Mining, ang output ay kadalasang patterns, trends, at predictive models na pwedeng gamitin sa decision-making. Halimbawa, pwede nitong ma-predict kung anong products ang posibleng bilhin ng customers o kung sino ang posibleng mag-avail ng isang service.

Sa Traditional Statistics naman, ang output ay statistical results tulad ng p-values, confidence intervals, at iba pang numerical results na tumutulong para ma-interpret kung valid o significant ba ang findings ng isang study.

So, sa madaling salita, pareho silang ginagamit sa pag-aanalyze ng data, pero magkaiba ang kanilang purpose at approach. Ang Data Mining ay mas nakatuon sa pag-discover ng hidden patterns at paggawa ng predictions gamit ang malalaking datasets. Samantalang ang Traditional Statistics ay mas nakatuon sa pag-test ng hypotheses at pag-validate ng existing theories gamit ang structured data. Pareho silang mahalaga, at ang pipiliin mong gamitin ay depende sa klase ng problem o data na gusto mong i-analyze.

**SLIDE 7:**
**TOPIC:**

Supervised Learning VS. Unsupervised Learning

**INSIGHTS:**

This slide only shows the second subtopic of the core concepts.

**SLIDE 8:**
**TOPIC:**

1. **Definition**

   **Supervised Learning** - (a type of Machine Learning) uses labeled data where the correct output is already known. The model learns by comparing its predictions to the actual answers.

   Example: emails are already marked as “spam” or “not spam,” and the system learns to sort new emails.

   **Unsupervised Learning** - uses unlabeled data where no correct output is provided. The model tries to find hidden patterns or structures on its own.

   Example: a store groups customers based on similar buying habits automatically.

**INSIGHTS:**

So, pag-usapan naman natin ang dalawang pangunahing uri ng Machine Learning, ang Supervised Learning at Unsupervised Learning. Unahin natin ang Supervised Learning. Ang Supervised Learning ay isang uri ng Machine Learning kung saan gumagamit tayo ng labeled data. Ibig sabihin, alam na natin ang tamang sagot o tamang output ng bawat data bago pa magsimula ang training ng system. Habang nag-aaral ang model, kino-compare nito ang sarili niyang prediction sa actual na sagot. Kapag mali ang prediction niya, ina-adjust niya ang sarili niya para mas maging accurate sa susunod.

Halimbawa, isipin natin ang email filtering. May mga email na naka-label na bilang "spam" at mayroon namang "not spam." Dahil alam na ng system kung alin ang tama, natututo ito kung paano i-classify ang mga bagong email na matatanggap sa future. Kaya kapag may bagong email na dumating, kaya na nitong hulaan kung spam ba iyon o hindi.

Ngayon naman, pumunta tayo sa Unsupervised Learning. Sa pagkakataong ito, gumagamit naman tayo ng unlabeled data. Ibig sabihin, wala nang nakalagay na tamang sagot o category. Bahala na ang model na maghanap ng similarities, patterns, o relationships sa data nang mag-isa.

Halimbawa naman nito ay sa isang grocery o department store. Marami silang customer na may iba't ibang binibili. Dahil walang labels ang data, susubukan ng system na i-group ang mga customers base sa kanilang buying habits. Halimbawa, mapapansin nitong may grupo ng customers na laging bumibili ng baby products, habang may ibang grupo naman na mas madalas bumili ng sports equipment. Dahil dito, mas madaling makagawa ang store ng tamang promotions o marketing strategies para sa bawat customer group.

So, ano ang pinakaiba nila? Ang Supervised Learning ay may guide o tamang sagot na sinusundan habang nag-aaral ang system. Samantalang ang Unsupervised Learning ay walang guide, kaya ang system mismo ang naghahanap ng patterns at relationships sa data.

Sa madaling salita, kung may labeled data at gusto nating gumawa ng predictions o classifications, mas angkop ang Supervised Learning. Pero kung gusto naman nating makahanap ng

hidden patterns o mag-group ng data kahit walang labels, Unsupervised Learning ang mas magandang gamitin. Pareho silang mahalagang bahagi ng Machine Learning dahil pareho silang nakakatulong sa pag-analyze ng data at paggawa ng mas matatalinong decisions.

**SLIDE 9:**
**TOPIC:**

2. **Objective**

**Supervised Learning** - aims to make accurate predictions or classifications based on input data. It focuses on learning a mapping from inputs to known outputs.

Example: predicting if a customer will buy a product or not.

**Unsupervised Learning** - aims to discover patterns, groupings, or relationships in data. It focuses on understanding the structure of the data.

Example: grouping customers into “frequent buyers” and “rare buyers.”

**INSIGHTS:**

Sunod naman ay objectives. Unahin natin ang Supervised Learning. Ang pangunahing objective ng Supervised Learning ay gumawa ng accurate predictions o classifications gamit ang existing o labeled data. Ang ibig sabihin ng labeled data ay mayroon na itong tamang sagot o output. Kaya habang tina-train ang system, natututo ito kung paano i-match ang input sa tamang output. Parang estudyante lang na may answer key habang nagre-review. Habang mas maraming examples ang nakikita niya, mas gumagaling siyang magbigay ng tamang sagot.

Halimbawa, gusto ng isang online shopping company na malaman kung bibili ba ng produkto ang isang customer o hindi. Gagamit sila ng previous customer data tulad ng age, purchase history, o browsing activity. Dahil alam na nila ang naging result ng mga dating customers, matututo ang system na mag-predict kung bibili rin ba ang bagong customer.

Sunod naman ay ang Unsupervised Learning.Ang objective naman nito ay mag-discover ng patterns, groupings, o relationships sa data. Ang kaibahan nito sa Supervised Learning ay wala itong labeled data. Ibig sabihin, walang answer key na ibibigay sa system. Siya mismo ang naghahanap ng pagkakapareho o differences sa data para makabuo ng mga groups o clusters.

Halimbawa, may isang business na maraming customer records pero hindi nila alam kung paano sila ikakategorya. Gamit ang Unsupervised Learning, puwedeng i-group ng system ang customers bilang frequent buyers, occasional buyers, o rare buyers base sa kanilang buying behavior. Hindi ito itinuro ng tao, kundi nadiskubre mismo ng system habang ina-analyze ang data.

So, ano ang pinakaiba nila? Ang Supervised Learning ay ginagamit kapag mayroon nang existing answers o labels at gusto nating gumawa ng prediction o classification. Samantalang ang Unsupervised Learning ay ginagamit kapag wala pang labels at gusto lang nating maintindihan ang structure ng data sa pamamagitan ng paghahanap ng patterns at groupings.

Sa madaling salita, parehong mahalaga ang dalawang ito sa Machine Learning. Ang pipiliing gamitin ay depende sa klase ng data na meron tayo at sa goal ng analysis. Kung ang objective ay mag-predict ng future outcomes, mas bagay ang Supervised Learning. Pero kung gusto nating makahanap ng hidden patterns o natural groupings sa data, mas angkop naman ang Unsupervised Learning.

**SLIDE 10:**
**TOPIC:**

3. **Data Requirements**

**Supervised Learning** - requires labeled datasets, which means data must be pre-classified. This often needs more time and effort to prepare.

Example: a list of customers labeled as “buyer” or “non-buyer.”

**Unsupervised Learning** - works with raw, unlabeled data. It is easier to collect but harder to interpret.

Example: just a list of customer purchases with no labels.

**INSIGHTS:**

Pangatlo naman ay Data Requirements. Unahin natin ang Supervised Learning. Ang Supervised Learning ay nangangailangan ng labeled dataset. Ibig sabihin, bago pa gamitin ang data, kailangan naka-classify na ito o may label na. Halimbawa, kung customer data ang ginagamit, nakalagay na agad kung sino ang "buyer" at sino ang "non-buyer." Dahil may labels na, mas madaling matutunan ng system ang pattern at makagawa ng predictions sa mga bagong data.

Pero ang downside nito ay mas matagal ang preparation. Kailangan munang i-review, i-organize, at lagyan ng tamang labels ang bawat data. Kaya mas maraming time at effort ang kailangan bago pa man makapag-training ang machine learning model.

Halimbawa, gusto mong gumawa ng system na kayang mag-predict kung bibili ba ang isang customer o hindi. Para magawa iyon, kailangan mong magbigay ng historical data na may labels na "buyer" o "non-buyer." Doon matututo ang system kung ano ang mga characteristics ng bawat grupo.

Ngayon naman, punta tayo sa Unsupervised Learning. Sa Unsupervised Learning, hindi na kailangan ng labeled data. Ang ginagamit nito ay raw o unlabeled data. Ibig sabihin, wala pang categories o classifications. Halimbawa, listahan lang ng mga binili ng customers ang meron ka, pero hindi mo alam kung sino ang buyer, loyal customer, o first-time customer.

Mas madali itong kolektahin dahil hindi mo na kailangang maglagay ng labels isa-isa. Pero ang challenge naman dito ay mas mahirap i-interpret ang resulta. Dahil walang labels, ang machine mismo ang naghahanap ng similarities o patterns sa data at gumagawa ng sariling groups o clusters.

Kaya minsan, kailangan pa ring i-analyze ng tao ang output para maintindihan kung ano ang ibig sabihin ng mga groups na nabuo.

So, sa madaling salita, ang Supervised Learning ay nangangailangan ng labeled data kaya mas matrabaho ang preparation, pero mas diretso at accurate ang predictions. Samantala, ang Unsupervised Learning ay gumagamit ng unlabeled data kaya mas madaling mag-collect ng data, pero mas challenging naman ang pag-interpret ng magiging resulta. Ang pagpili sa dalawa ay nakadepende pa rin sa kung anong klaseng data ang available at kung ano ang objective ng project o problem na gusto nating masolusyunan.

**SLIDE 11:**

**TOPIC:**

4. **Common Techniques**

   **Supervised Learning** - includes algorithms like classification and regression. Examples are decision trees and linear regression.

   Example: deciding if a loan should be approved or not.

   **Unsupervised Learning -** includes clustering and association methods. Examples are k-means clustering and hierarchical clustering.

   Example: finding which products are often bought together.

**INSIGHTS:**

Pangapat naman ay mga Common Techniques. Unahin natin ang Supervised Learning. Ang supervised learning ay isang technique kung saan may existing o labeled data na ginagamit para turuan ang system. Ibig sabihin, alam na natin ang tamang sagot o outcome, kaya natututo ang model base sa mga previous examples. Kapag natuto na ito, kaya na nitong mag-predict ng magiging result ng bagong data.

Dalawa sa mga common algorithms nito ay classification at regression. Ang classification ay ginagamit kapag ang output ay nasa categories lang, tulad ng "Yes" o "No", "Pass" o "Fail". Samantalang ang regression naman ay ginagamit kapag numerical values ang gustong i-predict, tulad ng presyo ng bahay o sales ng isang negosyo.

May mga example din ng algorithms dito tulad ng Decision Trees at Linear Regression. Ang Decision Tree ay parang flowchart na sunod-sunod ang mga tanong hanggang makabuo ng decision. Samantalang ang Linear Regression ay ginagamit para makita ang relationship ng mga variables at makapag-predict ng numerical values. Halimbawa, kung may bangko na tumatanggap ng loan applications, pwedeng gamitin ang supervised learning para malaman kung approved o hindi approved ang loan ng isang applicant base sa income, credit score, at iba pang impormasyon.

Pangalawa naman ay ang Unsupervised Learning. Hindi tulad ng supervised learning, dito wala tayong labeled data. Ibig sabihin, walang tamang sagot na ibinibigay sa system. Ang trabaho nito ay humanap ng hidden patterns o groups sa data nang mag-isa.

Dalawa sa mga common methods nito ay clustering at association. Ang clustering ay ginagamit para pagsama-samahin ang magkakaparehong data, habang ang association naman ay ginagamit para malaman kung anong mga items o events ang madalas na nangyayari nang sabay.
Ilan sa mga halimbawa nito ay ang K-Means Clustering at Hierarchical Clustering. Pareho silang ginagamit para mag-group ng data, pero magkaiba lang ang paraan kung paano nila ito ginagawa.

Isang magandang example nito ay sa mga supermarkets o online shopping apps. Sa pamamagitan ng unsupervised learning, nalalaman nila kung anong mga produkto ang madalas binibili nang magkasama. Halimbawa, kung ang bumibili ng tinapay ay kadalasan bumibili rin ng butter, pwede nila itong gamitin para sa product recommendations o promos.

So, sa madaling salita, ang Supervised Learning ay ginagamit kapag may existing data na pwedeng pagbasehan ng predictions, habang ang Unsupervised Learning naman ay ginagamit kapag gusto nating makahanap ng hidden patterns o relationships sa data kahit wala pang labels o tamang sagot.

**SLIDE 12:**
**TOPIC:**

5. **Output**

   **Supervised Learning** - produces predicted labels or values for new data. It is often used for tasks like spam detection or price prediction.

   Example: predicting if a customer will respond to a sale.

   **Unsupervised Learning -** produces groups or patterns within the data. It is often used for customer segmentation or pattern discovery.

   Example: grouping customers so a business can target them with different ads.

**INSIGHTS:**

At lastly is ung Output. Unahin natin ang Supervised Learning. Ang output ng Supervised Learning ay predicted labels o predicted values para sa bagong data. Ibig sabihin, dahil naturuan na ang model gamit ang labeled data, kaya na nitong magbigay ng prediction kapag may bagong information na ipinasok.

Halimbawa, ginagamit ito sa spam detection. Kapag may bagong email na dumating, kaya nitong i-predict kung spam ba iyon o hindi. Isa pang example ay price prediction, gaya ng pag-estimate ng presyo ng bahay o sasakyan base sa iba't ibang factors tulad ng location, size, o kondisyon.

Isang mas simpleng example ay ang predicting if a customer will respond to a sale. Halimbawa, may online shopping app na gustong malaman kung sino sa kanilang customers ang posibleng bumili kapag may sale. Dahil may previous customer data na sila, kaya ng Supervised Learning na i-predict kung sino ang mas malamang na mag-avail ng promo. Dahil dito, mas nagiging effective ang kanilang marketing strategy.

Punta naman tayo sa Unsupervised Learning.

Hindi tulad ng Supervised Learning, ang output ng Unsupervised Learning ay hindi prediction. Ang output nito ay groups o patterns na makikita sa data. Dahil wala itong labels, ang ginagawa nito ay hinahanap kung alin ang magkakapareho at automatic nitong pinapangkat ang mga iyon.

Halimbawa, ginagamit ito sa customer segmentation. Kung may libo-libong customers ang isang negosyo, kaya nitong i-group ang customers base sa kanilang buying habits, interests, o spending behavior. Hindi muna sinasabi ng system kung ano ang category nila. Siya mismo ang nakakahanap ng similarities.

Halimbawa, may isang group ng customers na madalas bumili ng gadgets, habang ang isa naman ay mas mahilig sa fashion products. Kapag na-group na sila, mas madaling gumawa ang negosyo ng iba't ibang advertisements na swak sa bawat customer group. Mas personalized ang marketing, kaya mas mataas ang chance na bumili ang customers.

So, sa madaling salita, ang Supervised Learning ay nagbibigay ng predictions para sa bagong data dahil may existing labels na itong pinagbasehan. Samantalang ang Unsupervised Learning naman ay naghahanap ng groups at hidden patterns sa data kahit walang labels. Pareho silang mahalaga, pero magkaiba ang klase ng output na kanilang napo-produce depende sa problemang gusto nating i-solve.

**SLIDE 13:**
**TOPIC:**

Classification, Regression, Clustering

**INSIGHTS:**

This slide only shows the third subtopic of the core concepts.

**SLIDE 14:**
**TOPIC:**

**CLASSIFICATION**

- is a technique used to assign data into specific categories or labels. It works by learning from past data to predict which category new data belongs to.

    - **Binary Classification**
        - is a type of classification that has only two possible outcomes. It separates data into one of two groups.

          Example: A bank decides if a loan application is approved or rejected.

**INSIGHTS:**

Ngayon naman, pag-usapan natin ang Classification. Ang Classification ay isang technique sa data mining at machine learning na ginagamit para i-assign o ilagay ang data sa tamang category o label. Sa madaling salita, tinuturuan muna natin ang system gamit ang mga existing o past data para matuto ito. Kapag natuto na ang system, kaya na nitong hulaan o i-classify ang mga bagong data na ipapasok.

Halimbawa, isipin natin na may email tayo. Paano nalalaman ng Gmail kung alin ang spam at alin ang hindi spam? Dahil gumagamit ito ng classification. Pinag-aaralan ng system ang mga dating emails at hinahanap ang common patterns. Kapag may bagong email na dumating na kahawig ng spam messages, automatic na nitong nilalagay sa spam folder.

Isa pang example ay sa mga online shopping apps. Kapag may bagong product na ina-upload, puwedeng gamitin ang classification para malaman kung kabilang ba ito sa electronics, clothing, food, o ibang category. Dahil dito, mas nagiging organized ang data at mas madaling hanapin ng users ang gusto nilang bilhin.

Ngayon naman, pag-usapan natin ang Binary Classification. Ang Binary Classification ay isang uri ng classification na dalawa lang ang possible na outcome. Ibig sabihin, dalawang grupo lang ang pagpipilian ng system. Pwedeng Yes o No, True o False, Approved o Rejected, depende sa situation.

Isang magandang example nito ay ang loan application sa bangko. Kapag may nag-apply ng loan, tinitingnan ng system ang iba't ibang impormasyon tulad ng income, credit history, at iba pang requirements. Pagkatapos ma-analyze ang data, magbibigay ito ng isang resulta lang, approved o rejected. Walang pangatlong option, kaya tinatawag itong binary classification.

Ginagamit din ang binary classification sa ibang applications. Halimbawa, sa medical field, puwedeng i-classify kung ang isang patient ay may sakit o wala base sa test results. Sa cybersecurity naman, ginagamit ito para malaman kung ang isang login attempt ay legitimate o suspicious.

So, in summary, ang Classification ay ang proseso ng paglalagay ng data sa tamang category gamit ang impormasyon mula sa mga dating data. Samantala, ang Binary Classification ay isang

special type ng classification kung saan dalawa lang ang possible na resulta. Dahil dito, mas napapadali ang decision-making ng mga systems at mas nagiging mabilis at accurate ang pagproseso ng impormasyon.

**SLIDE 15:**
**TOPIC:**

- **Multiclass Classification**
  - is a type of classification with more than two categories. It assigns data into one of several possible groups.

    Example: An online shop labels orders as low, medium, or high priority.

**INSIGHTS:**

Ngayon naman, pag-usapan natin ang Multiclass Classification. Ang Multiclass Classification ay isa pang type ng classification kung saan higit sa dalawa ang possible na categories o classes. Ibig sabihin, instead na dalawa lang ang pagpipilian, maraming pwedeng paglagyan ng isang data. Ang goal nito ay ma-classify o ma-assign ang bawat data sa isang tamang category mula sa ilang available na options.

Mas madaling maintindihan kung ikukumpara natin ito sa Binary Classification. Sa Binary Classification, dalawa lang ang choices, tulad ng Yes o No, Pass o Fail, o Spam o Not Spam. Pero sa Multiclass Classification, tatlo o higit pa ang choices. Halimbawa, pwedeng Low, Medium, at High, o kaya naman Red, Blue, Green, at Yellow depende sa problem na sinosolve.

Isa sa mga magandang example nito ay ang online shopping. Halimbawa, may system ang isang online shop na naglalagay ng priority sa bawat order. Imbes na pare-pareho ang treatment sa lahat ng orders, gumagamit sila ng Multiclass Classification para malaman kung ang order ba ay Low Priority, Medium Priority, o High Priority.

Kapag Low Priority, ibig sabihin hindi ito urgent at pwedeng iproseso mamaya. Kapag Medium Priority, normal lang ang processing nito. At kapag High Priority, mas inuuna itong iproseso dahil maaaring express delivery ito o mas importante ang order.

Hindi lang sa online shopping ginagamit ang Multiclass Classification. Makikita rin ito sa maraming applications. Halimbawa, sa education, pwede nitong i-classify ang performance ng students bilang Excellent, Good, Fair, o Needs Improvement. Sa healthcare naman, pwede nitong i-classify ang severity ng isang sakit bilang Mild, Moderate, o Severe. Marami rin itong gamit sa image recognition, customer segmentation, at recommendation systems.

So, sa madaling salita, ang Multiclass Classification ay ginagamit kapag tatlo o higit pa ang possible na categories ng data. Ang trabaho nito ay piliin ang pinakaangkop na category para sa bawat data. Dahil dito, mas nagiging organized ang information at mas nakakatulong ito sa paggawa ng mas mabilis at mas accurate na decisions sa iba't ibang fields tulad ng business, education, healthcare, at marami pang iba.

**SLIDE 16:**
**TOPIC:**

**REGRESSION**

- is a technique used to predict numerical or continuous values. It analyzes the relationship between variables to estimate future outcomes.

    - **Linear Regression**
        - assumes a straight-line relationship between input and output variables. It predicts values by fitting a line to the data.

          Example: A business predicts sales based on advertising budget.

**INSIGHTS:**

Sunod naman ay ang Regression. So, ano nga ba ang Regression? Ang regression ay isang technique na ginagamit para mag-predict ng numerical o continuous values. Ibig sabihin, imbes na category o label ang hinuhulaan, actual numbers ang pine-predict nito. Tinutulungan tayo ng regression na makita ang relationship ng iba't ibang variables para makapag-estimate ng magiging resulta sa future.

Halimbawa, gusto ng isang business na malaman kung magkano ang magiging sales nila next month. Isa sa mga factors na pwede nilang gamitin ay ang advertising budget. Doon papasok ang regression. Titingnan nito kung may relationship ba ang amount ng ginagastos sa advertisements at ang total sales ng negosyo. Kapag nakita na ang pattern, pwede na itong gamitin para mag-predict ng future sales.

Isa sa mga pinaka-common na uri ng regression ay ang Linear Regression. Ang Linear Regression ay nag-a-assume na ang relationship ng input at output variables ay straight line o diretso. Ibig sabihin, habang tumataas ang isang variable, inaasahan din na tataas o bababa ang isa pa sa consistent na paraan. Kaya gumagawa ito ng best-fit line na dumadaan sa data para mas madaling makapag-predict ng values.

Mas madali natin itong maintindihan sa isang example. Sabihin nating ang isang company ay gumagastos ng mas malaking budget sa advertisements kada buwan. Base sa kanilang previous data, napansin nila na habang tumataas ang advertising budget, tumataas din ang kanilang sales. Gagamitin ng Linear Regression ang historical data na iyon para gumawa ng isang line na magpapakita ng relationship ng dalawang variables. Pagkatapos, kung maglalagay sila ng bagong advertising budget, pwede nang i-estimate ng model kung magkano ang posibleng maging sales nila.

Hindi naman ibig sabihin na laging eksaktong tama ang prediction. May iba pa ring factors na pwedeng makaapekto, tulad ng competition, season, o customer demand. Pero malaking tulong pa rin ang Linear Regression dahil nagbibigay ito ng reasonable estimate na pwedeng maging basehan sa paggawa ng business decisions.

So, sa madaling salita, ang Regression ay ginagamit para mag-predict ng mga numerical values gamit ang relationship ng iba't ibang variables. At ang Linear Regression naman ay isang uri

ng regression na gumagamit ng straight-line relationship para makagawa ng predictions. Dahil dito, madalas itong ginagamit sa business, finance, marketing, at iba pang fields na nangangailangan ng forecasting at data analysis.

**SLIDE 17:**
**TOPIC:**

- **Nonlinear Regression**
  - is used when the relationship between variables is not a straight line. It can model more complex patterns in data.

    Example: A company predicts customer growth over time when growth speeds up.

**INSIGHTS:**

Ang Nonlinear Regression naman ay isa ring type ng regression na ginagamit kapag ang relationship ng dalawang variables ay hindi straight line. Ibig sabihin, hindi laging pantay o constant ang pagtaas at pagbaba ng data. Minsan, habang tumatagal, mas bumibilis o bumabagal ang pagbabago ng values. Dito pumapasok ang Nonlinear Regression dahil kaya nitong i-model ang mas komplikadong patterns na hindi kayang ipakita ng ordinaryong linear regression.

Kung matatandaan natin, sa Linear Regression, ang relationship ng variables ay diretso o straight line lang. Pero sa totoong buhay, hindi naman lahat ng data ay ganun kasimple. Maraming sitwasyon na pabago-bago ang trend, kaya mas angkop gamitin ang Nonlinear Regression.

Halimbawa, isipin natin ang isang kumpanya na gustong i-predict ang customer growth over time. Sa umpisa, maaaring mabagal lang ang pagdami ng customers dahil hindi pa gaanong kilala ang business. Pero habang mas maraming taong nakakakilala sa produkto o serbisyo nila, mas bibilis ang pagdami ng customers dahil sa recommendations at social media. Dahil hindi na ito sumusunod sa straight line, mas accurate gamitin ang Nonlinear Regression para maipakita ang totoong trend ng paglago.

Bukod sa customer growth, ginagamit din ang Nonlinear Regression sa iba't ibang fields. Halimbawa, sa biology, ginagamit ito para pag-aralan ang population growth ng mga hayop o halaman. Sa medicine naman, ginagamit ito para makita kung paano nagre-react ang katawan sa iba't ibang dosage ng gamot. Sa business at finance, nakakatulong din ito sa pag-aanalyze ng sales trends at forecasting ng future demand.

Ang advantage ng Nonlinear Regression ay mas kaya nitong mag-fit ng real-world data dahil hindi nito pinipilit na maging straight line ang relationship ng variables. Dahil dito, mas nagiging accurate ang predictions lalo na kung ang data ay may curves o mabilis na pagbabago.

Pero siyempre, may challenge din ito. Kumpara sa Linear Regression, mas complicated itong i-build at i-analyze dahil kailangan munang malaman kung anong klaseng nonlinear model ang pinakaangkop sa data. Kaya mas nangangailangan ito ng tamang analysis at minsan ay mas maraming computations.

So, overall, ang Nonlinear Regression ay ginagamit kapag ang relationship ng variables ay hindi linear o hindi straight line. Nakakatulong ito para ma-model ang mas realistic at complex na patterns ng data, kaya mas accurate ang predictions sa maraming real-world situations tulad ng customer growth, business forecasting, healthcare, at iba pang applications.

**SLIDE 18:**
**TOPIC:**

**CLUSTERING**

- is a technique used to group similar data points together without using predefined labels. It helps identify patterns or natural groupings within the data.

    - **Partition-based Clustering**
        - divides data into a fixed number of groups. Each data point belongs to the group with the nearest similarity.

          Example: A store groups customers into 3 groups based on spending habits.

**INSIGHTS:**

At lastly ay ang Clustering. So, ano nga ba ang Clustering? Ang clustering ay isang technique sa data mining na ginagamit para i-group ang mga magkakapareho o magkakahawig na data. Ang maganda rito, wala itong predefined labels. Ibig sabihin, hindi natin sasabihin sa system kung anong group ang bawat data. Siya mismo ang maghahanap ng similarities at magde-decide kung alin ang dapat pagsama-samahin.

Sa madaling salita, para itong pag-aayos ng mga bagay base sa pagkakapareho nila. Halimbawa, kung may halo-halong prutas sa isang basket, natural na pagsasamahin mo ang mga mansanas, hiwalay ang mga saging, at hiwalay din ang mga dalandan. Ganon din ang ginagawa ng clustering, pero sa data naman.

Ang main purpose ng clustering ay para makahanap ng hidden patterns o natural groupings sa data. Dahil dito, mas nagiging madali para sa mga companies o researchers na maintindihan ang malaking amount ng information at makagawa ng mas magandang decisions.

Isa sa mga pinakakaraniwang uri ng clustering ay ang Partition-based Clustering. Sa Partition-based Clustering, hinahati ang data sa fixed number of groups o clusters. Ibig sabihin, bago pa magsimula ang process, nakaset na kung ilang grupo ang gusto nating mabuo. Pagkatapos, bawat data point ay ilalagay sa group kung saan siya pinaka-magkakahawig o pinakamalapit ang similarity.

Halimbawa, isipin natin na may isang store na gustong pag-aralan ang spending habits ng kanilang customers. Napansin nila na iba-iba ang amount na ginagastos ng bawat customer. Kaya gumagamit sila ng Partition-based Clustering at hinahati nila ang customers sa tatlong groups.

Maaaring ang unang group ay mga customers na bihira lang bumili at maliit ang gastos. Ang ikalawang group naman ay mga regular customers na average ang spending. At ang ikatlong group ay

mga customers na madalas bumili at malaki ang nagagastos. Dahil dito, mas madali para sa store na gumawa ng iba't ibang promos o marketing strategies na babagay sa bawat grupo ng customers.

So, overall, ang Clustering ay isang technique na ginagamit para pagsama-samahin ang magkakaparehong data kahit wala pang labels. At ang Partition-based Clustering naman ay isang method kung saan hinahati ang data sa isang fixed na bilang ng groups para mas madaling makita ang mga patterns at mas maintindihan ang behavior ng mga data.

**SLIDE 19:**
**TOPIC:**

- **Hierarchical Clustering**
  - builds clusters step by step, forming a tree-like structure. It can show how data points are related at different levels.

    Example: A business groups customers from small groups into larger segments.

**INSIGHTS:**

Ang Hierarchical Clustering naman ay isa ring clustering technique kung saan unti-unting bino-build ang mga clusters step by step. Ang pinaka-unique dito ay gumagawa ito ng tree-like structure, na tinatawag ding hierarchy. Dahil dito, mas madali nating makita kung paano magkakaugnay ang mga data points mula sa maliliit na groups hanggang sa mas malalaking groups.

Para mas maintindihan, isipin niyo na lang ang family tree. Sa family tree, makikita natin kung sino ang magkakapamilya at paano sila konektado sa isa't isa. Ganun din ang Hierarchical Clustering. Pinapakita nito kung alin sa mga data ang pinaka-magkakahawig, tapos unti-unti silang pinagsasama hanggang sa makabuo ng mas malaking cluster.

Ang maganda sa Hierarchical Clustering ay hindi mo kailangan agad malaman kung ilang clusters ang gusto mong mabuo. Habang nagpapatuloy ang process, makikita mo mismo ang iba't ibang levels ng grouping. Kaya mas flexible ito kumpara sa ibang clustering methods.

Halimbawa naman sa isang business. Sabihin nating may kumpanya na gustong pag-aralan ang kanilang mga customers. Sa umpisa, maaaring may maliliit na grupo ng customers na may halos magkakaparehong buying habits. Habang tumatagal ang analysis, pinagsasama-sama ang mga maliliit na grupong ito hanggang sa makabuo ng mas malalaking customer segments. Sa ganitong paraan, mas naiintindihan ng kumpanya kung paano nila hahatiin ang kanilang customers para makapagbigay ng mas magandang products, services, o promotions.

Isa pang halimbawa ay sa online shopping. Maaaring mapansin ng system na may grupo ng customers na mahilig bumili ng gadgets, habang ang iba naman ay mas interested sa fashion. Habang ina-analyze ang data, makikita rin kung alin sa mga grupong ito ang may magkakaparehong preferences, kaya pwede silang pagsamahin sa mas malaking category.

So, in summary, ang Hierarchical Clustering ay isang technique na naggo-group ng data step by step hanggang makabuo ng tree-like structure. Dahil dito, mas madaling makita ang relationship ng

bawat data sa iba't ibang levels. Malaking tulong ito sa mga businesses at organizations dahil mas naiintindihan nila ang behavior ng kanilang customers at mas nakakagawa sila ng mas tamang decisions base sa mga groupings na nakita sa data.

**SLIDE 20:**
**TOPIC:**

**Data Mining: Applications & Techniques**

**Customer Segmentation**

- Dividing customers into groups based on shared characteristics like age, buying behavior, interests, or how often they use a service.

**Mining Technique: Clustering**

- The system looks at customer data and groups people who behave similarly.
- It does this automatically without needing labels or categories beforehand.
- It compares different factors (like spending or activity level) and puts similar customers into the same group.
- This helps businesses understand their customers better and create more targeted strategies.

**Examples**

- **Marketing Strategy**: A store finds a group of customers who spend a lot but shop rarely. Instead of giving discounts, they send exclusive VIP invitations to make them feel valued.
- **App Improvement**: A mobile app identifies “active users” and “inactive users.” It can then adjust features or notifications to better serve each group.

**INSIGHTS:**

Pag-usapan naman natin ang isa sa mga pinaka-common na applications ng Data Mining, at ito ay ang Customer Segmentation. Ano nga ba ang customer segmentation? Sa madaling salita, ito ay ang proseso ng paghahati-hati ng mga customers sa iba't ibang grupo base sa mga magkakapareho nilang katangian. Pwedeng base ito sa age, buying behavior, interests, o kung gaano sila kadalas gumamit ng isang produkto o serbisyo. Ang purpose nito ay para mas maintindihan ng isang business ang iba't ibang klase ng customers nila at makapagbigay ng mas angkop na products, services, o promotions.

Ngayon, ang pangunahing data mining technique na ginagamit dito ay ang Clustering. Ang clustering ay isang technique na automatic na naggo-group ng mga customers na may magkakaparehong behavior o characteristics. Ang maganda rito, hindi na kailangan ng labels o predefined categories. Ang system mismo ang naghahanap ng similarities sa data. Halimbawa, tinitingnan nito kung gaano kalaki ang ginagastos ng customer, gaano kadalas silang bumili, o gaano sila ka-active sa paggamit ng isang app. Kapag nakita ng system na magkahawig ang kanilang behavior, ilalagay sila sa iisang cluster o group.

Dahil dito, mas nagiging madali para sa mga businesses na maintindihan ang iba't ibang klase ng customers nila. Imbes na pare-pareho ang treatment sa lahat ng customers, pwede silang gumawa ng mas personalized at mas effective na strategies para sa bawat group.

Halimbawa, sa marketing strategy, may isang store na nakakita ng grupo ng customers na malaki ang ginagastos kada bili pero bihira lang mamili. Imbes na bigyan sila ng regular discounts, mas magandang strategy ang magpadala ng exclusive VIP invitations o special events. Sa ganitong paraan, mas nararamdaman nilang valued sila bilang loyal customers, at mas malaki ang chance na bumalik sila sa store.

Isa pang example ay sa mobile applications. Gamit ang clustering, kayang i-identify ng system kung sino ang mga active users at sino ang mga inactive users. Kapag alam na ito ng developers, pwede nilang baguhin ang features o notifications depende sa behavior ng bawat group. Halimbawa, ang inactive users ay pwedeng padalhan ng reminder o special offer para bumalik sa app, habang ang active users naman ay bibigyan ng bagong features o rewards bilang appreciation sa pagiging active nila.

So, overall, ang Customer Segmentation ay isang application ng data mining na tumutulong sa businesses na mas maintindihan ang kanilang customers. At sa tulong ng Clustering, nagagawa nitong automatic na i-group ang mga taong may magkakaparehong behavior. Dahil dito, mas nagiging personalized ang marketing, mas napapabuti ang customer experience, at mas nakakagawa ang mga kumpanya ng mas matalinong business decisions.

**SLIDE 21:**
**TOPIC:**

**Data Mining: Applications & Techniques**

**Fraud Detection**

- Identifying unusual or suspicious activities to prevent fraud, theft, or security problems.

**Mining Technique: Anomaly Detection & Classification**

- The system first learns what normal behavior looks like (e.g., usual spending patterns).
- If something very different happens, it flags it as suspicious.
- It can also learn from past fraud cases to recognize similar patterns in the future.
- This helps detect problems quickly, often in real time.

**Examples**

- **Banking Security**: You usually spend small amounts locally, then suddenly there's a large purchase in another country. The system flags or blocks it.
- **Healthcare Monitoring**: Detects when a provider claims too many services in a short time, which may not be possible.

**INSIGHTS:**

Sa Fraud Detection naman ay nagi-identify ng mga unusual o kahina-hinalang activities para maiwasan ang fraud, pagnanakaw, o iba pang security problems. Sa sobrang dami ng transactions na nangyayari araw-araw, halos imposible na itong bantayan lahat ng tao. Kaya gumagamit ang mga kumpanya ng data mining para awtomatikong ma-detect ang mga posibleng fraudulent activities.

Para magawa ito, gumagamit ang data mining ng Anomaly Detection at Classification. Una, ang Anomaly Detection. Ang ginagawa nito ay pinag-aaralan muna ng system kung ano ang normal na behavior. Halimbawa, sa isang bank account, natututo ito kung magkano ang usual na gastos ng isang customer, saan siya madalas bumili, at anong oras siya kadalasang gumagamit ng account. Kapag may nangyaring sobrang naiiba sa normal na pattern, automatic itong mafa-flag bilang suspicious.

Pangalawa naman ay ang Classification. Dito, tinuturuan ang system gamit ang mga previous fraud cases. Ibig sabihin, natututo ito mula sa mga dati nang fraudulent transactions para mas mabilis nitong makilala ang mga kahalintulad na pattern sa future. Habang mas maraming data ang natatanggap ng system, mas nagiging accurate din ang pag-detect nito.

Dahil sa dalawang techniques na ito, mas mabilis matutukoy ang mga posibleng problema, at kadalasan ay real-time pa ang detection. Ibig sabihin, bago pa tuluyang makumpleto ang isang fraudulent transaction, pwede na itong ma-block o ma-alert ang user.

Halimbawa, sa banking security, isipin nating ang normal mong gastos ay maliliit na purchases lang dito sa Pilipinas. Tapos bigla na lang may malaking transaction na ginawa sa ibang bansa gamit ang account mo. Dahil naiiba ito sa normal mong spending behavior, maaaring i-flag agad ng system ang transaction at pansamantalang i-block ito hanggang ma-confirm kung ikaw talaga ang gumawa.

Isa pang example ay sa healthcare monitoring. Halimbawa, may isang healthcare provider na biglang nag-claim ng napakaraming medical services sa loob lang ng maikling panahon. Dahil hindi ito normal at maaaring imposibleng mangyari, madi-detect ito ng system bilang suspicious at maaari itong i-review para malaman kung may fraud na nangyari.

So, sa madaling salita, malaking tulong ang data mining sa fraud detection dahil natutulungan nitong makita ang mga kahina-hinalang activities nang mas mabilis at mas accurate. Dahil dito, mas napoprotektahan ang pera, impormasyon, at seguridad ng mga tao at ng iba't ibang organizations.

**SLIDE 22:**
**TOPIC:**

**Data Mining: Applications & Techniques**

**Recommendation Systems**

- Systems that suggest products, movies, music, or content based on what a user likes.

**Mining Technique: Association Rules & Collaborative Filtering**

- The system studies your behavior (what you watch, buy, or listen to).
- It also compares your preferences with other users who have similar tastes.
- Then it recommends items that you might like but haven’t tried yet.
- Over time, the recommendations improve as the system learns more about you.

**Examples**

- **Streaming Platforms (like Netflix)**: Suggests movies or shows based on your watch history.

- **Online Shopping (like Amazon)**: Shows “Customers who bought this also bought…” to encourage more purchases.
- **Music Apps (like Spotify):** Recommends new songs or artists based on your listening habits.

## INSIGHTS:

Ang recommendation system naman ay isang system na nagbibigay ng suggestions ng products, movies, music, o kahit ibang content base sa interests at preferences ng isang user. Siguro napapansin niyo na kapag nanonood kayo ng movies o namimili online, may mga lumalabas na recommendations na parang alam na alam kung ano ang gusto niyo. Hindi iyon random. Resulta iyon ng data mining.

Ang recommendation systems ay gumagamit ng dalawang pangunahing techniques, ang Association Rules at Collaborative Filtering. Unahin natin ang Association Rules. Ang technique na ito ay naghahanap ng relationship sa pagitan ng iba't ibang items. Halimbawa, kung napansin ng system na maraming customers na bumibili ng laptop ay bumibili rin ng wireless mouse, automatic na ire-recommend din nito ang wireless mouse sa mga bibili ng laptop.

Pangalawa naman ay ang Collaborative Filtering. Dito naman, kino-compare ng system ang preferences mo sa ibang users na may halos kaparehong interests. Halimbawa, kung pareho kayo ng pinapanood na movies ng ibang user, tapos may movie siyang napanood na hindi mo pa nakikita, malaki ang chance na iyon ang ire-recommend sa'yo ng system.

Ganito ang proseso ng recommendation system. Una, pinag-aaralan nito ang behavior mo, tulad ng mga pinapanood, binibili, o pinapakinggan mo. Pagkatapos, kino-compare nito ang preferences mo sa ibang users na may similar interests. Pagkatapos ng analysis, magbibigay ito ng recommendations ng mga items na posibleng magustuhan mo kahit hindi mo pa nasusubukan. Habang mas madalas mong ginagamit ang system, mas lalo itong natututo tungkol sa preferences mo kaya mas nagiging accurate ang recommendations.

Marami tayong nakikitang examples nito sa araw-araw. Halimbawa, sa mga streaming platforms tulad ng Netflix, nagre-recommend ito ng movies o TV shows base sa watch history mo. Sa online shopping websites tulad ng Amazon, may feature silang "Customers who bought this also bought..." para makapag-suggest ng iba pang products. At sa music apps tulad ng Spotify, nagre-recommend ito ng bagong songs, playlists, o artists base sa mga music na madalas mong pakinggan.

So, sa madaling salita, ang recommendation system ay isang application ng data mining na tumutulong para mas maging personalized ang experience ng bawat user. Dahil dito, mas madali nating nadidiskubre ang mga products o content na posibleng magustuhan natin.

## SLIDE 23:
## TOPIC:

**Data Mining: Applications & Techniques**

**Predictive Maintenance**

- Using data to predict when a machine or system might fail so it can be fixed before it breaks.

**Mining Technique: Regression & Neural Networks**

- Sensors collect data from machines (such as temperature, vibration, or usage time).
- The system analyzes this data to find patterns that indicate possible failure.
- It predicts when maintenance is needed, helping avoid sudden breakdowns.
- This saves money, time, and prevents dangerous situations.

**Examples**

- **Airlines**: Aircraft systems monitor engine performance and detect issues early to prevent accidents or delays.
- **Factories**: Machines are repaired during scheduled breaks before they fail, avoiding production stoppage.
- **Utilities**: Water systems detect small leaks or pressure changes early, preventing major pipe bursts.

## INSIGHTS:

Sa Predictive Maintenance naman ay technique kung saan ginagamit ang data para ma-predict kung kailan posibleng masira ang isang machine o system. Sa halip na hintayin pang magkaroon ng sira bago ito ayusin, naaagapan na agad ang problema. Dahil dito, mas nakakaiwas ang mga kumpanya sa biglaang breakdown ng kanilang mga equipment.

Para magawa ito, gumagamit ang data mining ng mga techniques tulad ng Regression at Neural Networks. Una, ang Regression ay ginagamit para mag-predict ng future values base sa mga existing data. Halimbawa, kung napapansin na tumataas ang temperature ng isang machine habang tumatagal ang paggamit nito, pwedeng gamitin ang regression para i-estimate kung kailan ito aabot sa delikadong level.

Samantala, ang Neural Networks ay isang machine learning technique na kayang makakita ng mas komplikadong patterns sa data. Mas effective ito kapag maraming factors ang kailangang i-consider, kaya mas accurate ang prediction kung kailan posibleng magkaroon ng failure ang isang machine.

Paano nga ba ito gumagana? Una, may mga sensors na nakakabit sa machine. Ang mga sensors na ito ay nangongolekta ng iba't ibang impormasyon tulad ng temperature, vibration, at usage time. Pagkatapos, ina-analyze ng system ang lahat ng data na ito para makita kung may mga patterns na nagpapakita na malapit nang magkaroon ng problema. Kapag may na-detect na possible issue, nagbibigay ito ng warning para maayos agad ang machine bago pa ito tuluyang masira.

Malaki ang naitutulong nito dahil nakakatipid sa oras, gastos, at maintenance cost. Bukod pa rito, nakakaiwas din ito sa mga aksidente at hindi inaasahang paghinto ng operasyon. Halimbawa, sa airlines, mino-monitor ang performance ng aircraft engines para ma-detect agad kung may abnormal na nangyayari. Dahil dito, naiiwasan ang aksidente at nababawasan ang flight delays.

Sa mga factories, inaayos ang mga machines habang naka-schedule ang maintenance, kaya hindi naaabala ang buong production process. At sa water utilities, ginagamit ito para ma-detect ang maliliit na leaks o pagbabago sa water pressure bago pa ito maging malaking problema tulad ng pagputok ng mga tubo.

So, overall, ang Predictive Maintenance ay isang magandang application ng data mining dahil nakakatulong itong mapahaba ang buhay ng mga machines, mabawasan ang gastos, at mapanatiling ligtas at tuloy-tuloy ang operasyon ng iba't ibang industriya.

**SLIDE 24:**
**TOPIC:**

**Data Mining: Applications & Techniques**

**Healthcare & Medical Diagnostics**

- Using patient data (medical records, images, and test results) to help doctors detect diseases earlier and make more accurate diagnoses.

**Mining Technique: Deep Learning & Classification**

- It learns patterns of what “normal” and “abnormal” look like.
- When new data is given, it compares it with what it has learned and classifies it (e.g., healthy vs diseased).
- Deep learning is especially powerful because it can detect very small or hidden details that humans might miss.
- This helps doctors make faster and more reliable decisions.

**Examples**

- **Tumor Detection:** AI analyzes medical images (like X-rays or MRIs) and highlights possible cancer areas, even in very early stages.
- **Disease Diagnosis Support:** Systems assist doctors by suggesting possible illnesses based on symptoms and test results, improving accuracy.

**SLIDE 25:**
**TOPIC:**

**KEY TECHNIQUES**

- Decision Trees & Random Forests
- Support Vector Machines (SVM)
- Association Rules (Market Basket Analysis)
- Neural Networks

**INSIGHTS:**

This is only the slide containing the Key Techniques and four of its subtopics.

**SLIDE 26:**
**TOPIC:**

**DECISION TREES**

**WHAT IS IT?**

- A tree-like model for classification and regression

**ORIGIN**

- Developed in the 1960s
- Popularized by Ross Quinlan (ID3, C4.5 algorithms)

**HOW IT WORKS?**

- Splits data into branches based on conditions
- Ends in leaf nodes (final decision)

**EXAMPLE**

Predict if a customer will buy:

- Age < 30 → No
- Age ≥ 30 → Yes

## INSIGHTS:

Ngayon, ang Decision Tree ay isang tree-like model na ginagamit para sa classification at regression. Ang classification ay ginagamit kapag ang output ay categories, halimbawa kung "Yes" o "No" ang magiging sagot. Samantalang ang regression naman ay ginagamit kapag numerical values ang gusto nating i-predict, tulad ng presyo o sales.

Tinawag itong Decision Tree dahil ang itsura nito ay parang puno. Mayroon itong root, pagkatapos ay may mga branches, at sa dulo ay may mga leaf nodes. Ang bawat branch ay kumakatawan sa isang kondisyon o tanong, habang ang leaf node ang nagbibigay ng final decision o final prediction.

Pagdating naman sa origin nito, nagsimula ang paggamit ng Decision Trees noong 1960s, pero mas lalo itong sumikat dahil kay Ross Quinlan, na gumawa ng mga sikat na algorithms tulad ng ID3 at C4.5. Ang mga algorithms na ito ang tumutulong sa system para malaman kung anong tanong o condition ang pinakamagandang gamitin sa bawat branch ng tree.

Paano naman ito gumagana? Simple lang ang concept nito. Inuumpisahan nito ang lahat ng data sa isang root node. Pagkatapos, hahatiin nito ang data base sa isang condition o tanong. Kapag may panibagong kondisyon, hahatiin ulit ang data hanggang sa makarating ito sa leaf node, kung saan makukuha na ang final decision.

Mas madaling maintindihan kapag may example. Halimbawa, gusto nating i-predict kung bibili ba ang isang customer ng produkto. Ang unang condition ay maaaring tungkol sa edad. Kapag ang Age ay less than 30, ang magiging prediction ay No, ibig sabihin hindi bibili ang customer. Pero kapag ang Age ay 30 or above, ang magiging prediction naman ay Yes, ibig sabihin mas malaki ang chance na bibili siya.

So, sa madaling salita, ang Decision Tree ay isang madaling intindihing technique sa data mining dahil para lang itong flowchart na gumagamit ng sunod-sunod na tanong para makarating sa tamang decision. Dahil simple itong basahin at i-interpret, isa ito sa mga pinaka-common na ginagamit sa data analysis, machine learning, at business decision-making.

**SLIDE 27:**
**TOPIC:**

**RANDOM FOREST**

**WHAT IS IT?**

- A collection (ensemble) of multiple decision trees

**ORIGIN**

- Introduced by Leo Breiman (2001)

**HOW IT WORKS?**

- Builds many trees using random samples
- Combines outputs (majority vote)

**WHY USE IT?**

- Higher accuracy than single trees
- Reduces overfitting

**EXAMPLE**

Fraud detection:

- Tree 1 → Fraud
- Tree 2 → Not Fraud
- Tree 3 → Fraud
- → Final: Fraud

**INSIGHTS:**

Sa Random Forest naman, ‘to ay isang machine learning algorithm na binubuo ng maraming decision trees. Ang tawag dito ay ensemble method dahil imbes na isang decision tree lang ang gagamitin, pinagsasama-sama nito ang maraming decision trees para makagawa ng mas accurate na prediction. Isipin niyo na lang na parang humihingi tayo ng opinyon sa maraming tao kaysa umasa lang sa iisang tao. Mas mataas ang chance na tama ang magiging final decision.

Ang Random Forest ay ipinakilala ni Leo Breiman noong 2001. Layunin niyang gumawa ng mas reliable na algorithm na kayang magbigay ng mas accurate na predictions kumpara sa paggamit

ng isang decision tree lang. Hanggang ngayon, isa pa rin ito sa mga pinakasikat at pinakaginagamit na algorithms sa Machine Learning dahil sa magandang performance nito.

Paano naman ito gumagana? Una, gumagawa ang Random Forest ng maraming decision trees gamit ang iba't ibang random samples ng data. Ibig sabihin, hindi pare-pareho ang data na ginagamit ng bawat tree. Dahil dito, iba-iba rin ang magiging prediction ng bawat isa. Kapag tapos na silang lahat magbigay ng resulta, pagsasamahin ng Random Forest ang kanilang mga predictions gamit ang majority vote. Kung ano ang pinakamaraming sagot ng mga decision trees, iyon ang magiging final prediction.

Bakit natin ginagamit ang Random Forest? Una, mas mataas ang accuracy nito kumpara sa paggamit ng isang decision tree lang. Dahil maraming trees ang nagtutulungan, mas nagiging reliable ang prediction. Pangalawa, nakakatulong itong mabawasan ang overfitting. Ang overfitting ay nangyayari kapag sobrang kabisado na ng model ang training data kaya nahihirapan na itong magbigay ng tamang prediction sa bagong data. Dahil random ang pagpili ng data at maraming decision trees ang ginagamit, mas nagiging balanced ang model at mas maganda ang performance nito.

Halimbawa, gamitin natin ito sa fraud detection. Sabihin nating may tatlong decision trees. Si Tree 1 ay nagsabing Fraud, si Tree 2 naman ay nagsabing Not Fraud, at si Tree 3 ay nagsabing Fraud. Dahil dalawa sa tatlong trees ang nagsabing Fraud, iyon ang magiging final prediction ng Random Forest.

So, sa madaling salita, ang Random Forest ay isang collection ng maraming decision trees na nagtutulungan para makagawa ng mas accurate at mas reliable na predictions. Dahil sa mataas nitong accuracy at kakayahang mabawasan ang overfitting, isa ito sa mga pinakaepektibong algorithms na ginagamit sa iba't ibang applications tulad ng fraud detection, medical diagnosis, at customer behavior prediction.

**SLIDE 28:**
**TOPIC:**

**SUPPORT VECTOR MACHINES (SVM)**

**WHAT IS IT?**

- A supervised learning model for classification/regression

**ORIGIN**

- Developed in the 1990s by Vladimir Vapnik

**HOW IT WORKS?**

- Finds the best boundary (hyperplane) separating classes
- Maximizes margin between data points

**WHY USE IT?**

- Higher accuracy than single trees
- Reduces overfitting

**EXAMPLE**

Email classification:

- Spam vs Not Spam
- SVM draws a line separating both groups

## INSIGHTS:

Ang SVM naman ay isang supervised learning model na ginagamit para sa classification at minsan ay regression. Ang ibig sabihin ng supervised learning ay may existing o labeled data na itong ginagamit para matuto. Halimbawa, alam na natin kung alin ang spam at hindi spam na emails, kaya doon natututo ang model kung paano mag-classify ng bagong data.

Ang SVM ay na-develop noong 1990s ni Vladimir Vapnik. Hanggang ngayon, isa pa rin ito sa mga kilalang machine learning algorithms dahil sa accuracy nito, lalo na kapag ang data ay may malinaw na paghihiwalay ng mga categories.

Paano naman ito nagwo-work? Ang pangunahing goal ng SVM ay maghanap ng best boundary, na tinatawag na hyperplane, para paghiwalayin ang iba't ibang classes ng data. Ang boundary na ito ang nagsisilbing linya o divider sa pagitan ng dalawang groups.

Hindi lang basta naghahanap ng linya ang SVM. Sinisigurado rin nitong pinakamalaki ang margin, o ang distansya ng boundary mula sa pinakamalalapit na data points ng bawat class. Kapag mas malaki ang margin, mas nagiging accurate at mas maganda ang performance ng model sa pag-classify ng bagong data.

Bakit natin ginagamit ang SVM? Isa sa pinakamalaking advantage nito ay mas mataas ang accuracy kumpara sa ibang simpleng models tulad ng single decision tree. Bukod pa rito, nakakatulong din itong maiwasan ang overfitting. Ang overfitting ay nangyayari kapag sobrang kabisado ng model ang training data kaya nahihirapan na itong magbigay ng tamang prediction sa bagong data. Dahil sa paraan ng SVM sa pagpili ng best boundary, mas nagiging reliable ang predictions nito.

Halimbawa, sa email classification, may dalawang klase ng emails: Spam at Not Spam. Kapag maraming sample emails ang ibinigay sa SVM, aaralin nito ang mga characteristics ng bawat grupo. Pagkatapos, maglalagay ito ng boundary o linya na naghihiwalay sa spam at hindi spam. Kapag may bagong email na dumating, iche-check lang ng SVM kung saang side ng boundary ito nabibilang, at doon nito malalaman kung spam ba ito o hindi.

So, sa madaling salita, ang Support Vector Machine ay isang supervised learning algorithm na naghahanap ng pinakamagandang boundary para paghiwalayin ang iba't ibang classes ng data. Dahil sa mataas nitong accuracy at kakayahang mabawasan ang overfitting, isa ito sa mga madalas gamitin sa machine learning at data mining applications.

**SLIDE 29:**
**TOPIC:**

**ASSOCIATION RULES (MARKET BASED ANALSIS)**

**WHAT IS IT?**

- Discovers relationships between items in datasets

**ORIGIN**

- Introduced by Agrawal, Imielinski, and Swami (1993)

**HOW IT WORKS?**

- Identifies frequent item combinations

**APPLICATIONS**

- Product recommendations
- Store layout optimization

**EXAMPLE**

Supermarket:

- Bread → Butter
- Diapers → Beer

## INSIGHTS:

Ang Association Rules o Market Basket Analysis naman ay isang data mining technique na ginagamit para madiskubre ang relationship ng iba't ibang items sa isang dataset. Sa madaling salita, hinahanap nito kung anong mga bagay ang madalas na magkasamang nangyayari o binibili. Kaya tinawag itong Market Basket Analysis dahil madalas itong ginagamit sa mga supermarket at grocery stores para pag-aralan ang laman ng shopping basket ng mga customers.

Ang concept na ito ay unang ipinakilala nina Agrawal, Imielinski, at Swami noong 1993. Ang goal nila ay gumawa ng paraan para ma-analyze ang napakaraming transaction records at makita kung may pattern ba sa mga binibili ng mga tao.

Paano naman ito gumagana? Simple lang ang idea nito. Sinusuri nito ang lahat ng transactions at hinahanap kung anong combinations ng products ang madalas na magkasama. Kapag paulit-ulit na lumalabas ang parehong combination, ibig sabihin may association o relationship sa pagitan ng mga items na iyon.

Halimbawa, kung mapapansin ng system na karamihan sa mga bumibili ng tinapay ay bumibili rin ng butter, mababuo ang association na Bread → Butter. Hindi ibig sabihin na siguradongbibili ng butter ang lahat ng bumili ng bread, pero ipinapakita lang nito na mataas ang chance na magkasama silang bilhin.

Marami ring applications ang Association Rules. Isa na rito ang product recommendations. Halimbawa, kapag nag-online shopping ka sa Shopee o Lazada, mapapansin mo na may lumalabas na "Customers also bought" o "Frequently bought together." Hindi lang iyon random. Ginagamit nila ang Association Rules para magbigay ng mas relevant na recommendations.

Isa pa ay ang store layout optimization. Halimbawa, kung nalaman ng supermarket na madalas magkasama ang dalawang produkto, pwede nilang ilagay ang mga ito nang magkalapit para mas madali itong makita ng customers at mas tumaas ang sales.

Isa pang classic na example ay ang Diapers → Beer. Sa ilang studies, napansin na may mga customers na bumibili ng diapers at beer sa iisang transaction. Dahil dito, may mga stores na inilalagay ang dalawang products na ito malapit sa isa't isa para mas maging convenient sa customers.

So, overall, ang Association Rules ay isang technique sa data mining na tumutulong sa pag-discover ng relationships sa pagitan ng mga items. Dahil dito, mas nakakapagbigay ang mga businesses ng better product recommendations, mas maayos na store arrangement, at mas magandang customer experience.

**SLIDE 30:**
**TOPIC:**

**NEURAL NETWORKS**

**WHAT IS IT?**

- A model inspired by the human brain

**ORIGIN**

- First concept in 1940s (McCulloch & Pitts)
- Popularized in modern AI (Deep Learning era)

**HOW IT WORKS?**

- Learns patterns by adjusting weights

**WHY USE IT?**

- Higher accuracy than single trees
- Reduces overfitting

**EXAMPLE**

Image recognition:

- Input: picture of an animal
- Output: “Dog” or “Cat”

**INSIGHTS:**

Tapos sa Neural Network naman ay isang computer model na inspired sa kung paano gumagana ang human brain. Kung paano natututo ang utak natin mula sa experience at paulit-ulit na practice, ganun din ang concept ng neural network. Habang mas maraming data ang napo-process nito, mas lalo itong natututo at mas gumagaling sa paggawa ng predictions o pag-recognize ng patterns.

Pagdating naman sa origin nito, nagsimula ang pinakaunang concept ng Neural Networks noong 1940s sa pamamagitan nina McCulloch at Pitts. Sila ang nagpakilala ng ideya na pwedeng gayahin ng computer ang simpleng proseso ng pag-iisip ng tao. Pero hindi pa noon ganoon kalakas ang technology kaya limitado pa ang paggamit nito. Nang magkaroon ng mas mabilis na computers at mas maraming available na data, lalo itong sumikat sa panahon ng Modern AI o mas kilala ngayon bilang Deep Learning.

Paano naman ito gumagana? Simple lang ang idea. Ang neural network ay natututo sa pamamagitan ng paulit-ulit na pag-aanalyze ng data. Habang nagte-training ito, ina-adjust niya ang tinatawag na weights o values sa loob ng system para mas maging accurate ang resulta. Kapag nagkamali ang prediction, ina-adjust ulit ang mga weights hanggang sa makahanap ng mas tamang sagot. Kaya habang mas marami itong training data, mas tumataas din ang accuracy nito.

Bakit nga ba ginagamit ang Neural Networks? Isa sa pinakamalaking advantage nito ay mas mataas ang accuracy kumpara sa mga simpleng decision tree models, lalo na kapag komplikado ang data. Bukod doon, nakakatulong din ito sa pagre-reduce ng overfitting, ibig sabihin, hindi lang nito mina-memorya ang training data kundi natututo rin itong magbigay ng tamang prediction kahit sa bagong data na hindi pa nito nakikita.

Halimbawa, isipin natin ang image recognition. Magbibigay tayo ng picture ng isang hayop bilang input. I-aanalyze ng neural network ang iba't ibang features ng image tulad ng hugis, tenga, mata, at iba pang details. Pagkatapos, ibibigay nito ang output kung ang nasa larawan ba ay "Dog" o "Cat."

So, overall, ang Neural Networks ay isa sa pinakamahalagang technologies sa Artificial Intelligence dahil kaya nitong matuto mula sa data, makahanap ng complex patterns, at makagawa ng mas accurate na predictions na ginagamit ngayon sa iba't ibang AI applications.

**SLIDE 31:**
**TOPIC:**

**EVALUATION & CHALLENGES**

- Accuracy Metrics (Precision/Recall/F1)
- Bias & Privacy Concerns
- Big Data Challenges

**INSIGHTS:**

This is only the slide containing Evaluation and Challenges and three of its subtopics.

**SLIDE 32:**
**TOPIC:**

**ACCURACY METRICS**

**Precision**

- Measures the accuracy of positive predictions (minimizes False Positives).

$$\text{Precision} = \frac{\text{TruePositives}}{\text{TruePositives} + \text{FalsePositives}}$$

**Recall**

- Measures the ability to find all actual positive cases (minimizes False Negatives).

$$\text{Recall} = \frac{\text{TruePositives}}{\text{TruePositives} + \text{FalseNegatives}}$$

**F1-Score**

- The harmonic mean that balances the trade-off between Precision and Recall.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

**INSIGHTS:**

Ngayon naman, pag-usapan natin ang Accuracy Metrics. Ito ang mga sukatan na ginagamit para malaman kung gaano kaayos o ka-accurate ang performance ng isang machine learning o data mining model. Tatlo sa mga pinaka-common na metrics ay ang Precision, Recall, at F1-Score.

Unang-una ay ang Precision. Ang Precision ay sumusukat kung gaano ka-accurate ang mga positive predictions ng model. Sa madaling salita, kapag sinabi ng system na positive ang isang result, tinitingnan nito kung ilan talaga doon ang totoong positive. Ang goal ng Precision ay mabawasan ang False Positives, o yung mga maling na-classify bilang positive kahit hindi naman talaga. Ang formula ng Precision ay True Positives divided by the sum of True Positives and False Positives. Mas mataas ang Precision, mas kaunti ang maling positive predictions ng model.

Sunod naman ay ang Recall. Ang Recall ay sumusukat kung gaano kagaling ang model sa paghahanap ng lahat ng actual positive cases. Hindi naman ito masyadong concerned kung may ilang maling positive, ang mas importante rito ay hindi mamiss ang mga totoong positive cases. Kaya ang goal nito ay mabawasan ang False Negatives, o yung mga dapat positive pero hindi na-detect ng system. Ang formula ng Recall ay True Positives divided by the sum of True Positives and False Negatives. Kapag mataas ang Recall, ibig sabihin mas maraming actual positive cases ang nahahanap ng model.

Pangatlo ay ang F1-Score. Ang F1-Score ay ginagamit kapag gusto nating magkaroon ng balance sa pagitan ng Precision at Recall. Kasi minsan, kapag pinataas natin ang Precision, bumababa naman ang Recall, at vice versa. Kaya ang F1-Score ang nagbibigay ng mas balanced na evaluation. Ang formula nito ay 2 multiplied by Precision times Recall, divided by Precision plus Recall. Tinatawag din itong harmonic mean ng Precision at Recall.

Halimbawa, isipin natin na ang system ay ginagamit para mag-detect ng spam emails. Mahalaga ang Precision para hindi ma-classify bilang spam ang mga normal na emails. Mahalaga rin ang Recall para hindi makalusot ang mga totoong spam messages. At ang F1-Score ang tumutulong para mabalanse ang dalawang ito.

So, overall, ang Precision, Recall, at F1-Score ay mahalagang accuracy metrics na ginagamit para masukat ang performance ng isang model. Hindi lang basta accuracy ang tinitingnan, kundi kung gaano ito ka-reliable sa paggawa ng tamang predictions depende sa sitwasyon.

**SLIDE 33:**
**TOPIC:**

**BIAS IN DATA MINING**

**Systemic Bias**
- Algorithms can learn, automate, and amplify historical prejudices present in the training data.

**Unrepresentative Data**
- Lack of diversity in datasets leads to discriminatory outcomes for underrepresented groups.

**Feedback Loops**
- Flawed predictions influence future data collection, constantly reinforcing the algorithm's bias.

**INSIGHTS:**

Kapag sinabing bias, ibig sabihin ay may unfairness o pagkakaroon ng pabor sa isang tao, grupo, o klase ng data. Kahit na computer o algorithm ang nagpo-process ng data, posible pa rin itong magkaroon ng bias. Bakit? Kasi ang algorithm ay natututo lang base sa data na ibinibigay natin. Kung may mali o may bias na ang data, malaki ang chance na gayahin din iyon ng algorithm.

Unang uri ng bias ay ang Systemic Bias. Ang Systemic Bias ay nangyayari kapag ang historical data na ginagamit sa training ay may existing prejudice o unfair treatment. Dahil dito, natututo ang algorithm na ulitin at minsan ay lalo pang palakasin ang bias na iyon. Halimbawa, kung ang historical hiring records ng isang kumpanya ay mas pinipili ang isang grupo ng applicants kaysa sa iba, maaaring ganoon din ang maging recommendation ng AI kahit pare-pareho naman ang qualifications ng applicants.

Pangalawa naman ay ang Unrepresentative Data. Nangyayari ito kapag kulang ang diversity ng data na ginagamit. Ibig sabihin, may mga grupo ng tao na hindi sapat ang representation sa dataset.

Dahil dito, hindi natututo nang maayos ang algorithm tungkol sa kanila, kaya posible itong magbigay ng inaccurate o unfair results. Halimbawa, kung ang facial recognition system ay mas maraming images ng isang race kaysa sa iba, mas mataas ang chance na magkamali ito sa pag-identify ng mga taong kulang ang representation sa dataset.

At ang huli ay ang Feedback Loops. Ang Feedback Loop ay nangyayari kapag ang prediction ng algorithm ay nakakaapekto sa mga susunod na data na makokolekta. Dahil dito, paulit-ulit lang nitong napapalakas ang parehong bias. Halimbawa, kung ang isang system ay laging nagre-recommend ng iisang klase ng content, iyon lang din ang madalas panoorin o i-click ng users. Sa huli, iisipin ng algorithm na iyon lang talaga ang gusto ng mga tao, kaya lalo nitong inuulit ang parehong recommendation.

So, sa kabuuan, mahalagang iwasan ang bias sa data mining dahil maaari itong magdulot ng unfair decisions at discrimination. Kaya dapat siguraduhin na ang data ay accurate, diverse, at maayos ang pag-train ng algorithm para maging mas patas at mas reliable ang mga resulta.

**SLIDE 34:**
**TOPIC:**

**PRIVACY AND SECURITY CONCERNS**

**Informed Consent**

- User data is frequently scraped or mined without explicit permission or awareness.

**De-anonymization**

- Advanced algorithms can cross-reference "anonymized" datasets to re-identify specific individuals.
-

**Security Risks**

- Centralizing massive amounts of personal data creates a high-value target for cyberattacks and data breaches.

**INSIGHTS:**

Pag-usapan naman natin ang isa sa pinakamahalagang issues sa data mining, ang Privacy and Security Concerns. Habang napakaraming benefits ang data mining, may mga risks din na kailangan nating pagtuunan ng pansin, lalo na pagdating sa personal information ng mga users.

Unang concern ay ang Informed Consent. Ang informed consent ay nangangahulugan na dapat alam at pumapayag ang isang tao bago kolektahin o gamitin ang kanyang personal data. Pero sa totoong buhay, hindi ito laging nangyayari. Maraming websites, apps, at online services ang kumokolekta ng user data nang hindi masyadong napapansin ng mga users. Minsan, basta na lang tayo nagki-click ng "Accept" sa terms and conditions nang hindi binabasa, kaya hindi natin namamalayan na pumapayag na pala tayo sa pagkuha at paggamit ng ating impormasyon. Dahil dito, nagkakaroon ng concern kung talagang may sapat bang consent ang users.

Pangalawang concern ay ang De-anonymization. May mga pagkakataon na ang personal data ay ginagawang anonymous o tinatanggalan ng pangalan para maprotektahan ang identity ng isang tao. Pero dahil sa advanced algorithms at modern technology, posible pa ring maibalik o ma-identify kung sino ang may-ari ng data. Halimbawa, kahit wala nang pangalan ang isang dataset, kapag pinagsama ito sa ibang impormasyon mula sa iba't ibang sources, maaaring matukoy pa rin kung sino ang taong tinutukoy. Kaya kahit anonymous na ang data, hindi pa rin ibig sabihin na guaranteed na ligtas ang privacy ng users.

At ang huling concern ay ang Security Risks. Sa data mining, napakaraming personal information ang iniimbak sa iisang database o system. Dahil dito, nagiging malaking target ito ng mga hackers at cybercriminals. Kapag nagkaroon ng data breach o cyberattack, maaaring manakaw ang personal information tulad ng pangalan, address, contact number, email, o kahit financial information ng mga users. Bukod sa pagkawala ng privacy, maaari rin itong magdulot ng identity theft, online scams, at iba pang cybercrimes.

So, overall, kahit malaking tulong ang data mining sa businesses, organizations, at research, mahalaga pa ring bigyang pansin ang privacy at security ng users. Dapat siguraduhin na may tamang consent bago gamitin ang data, may sapat na proteksyon laban sa paglabag sa privacy, at may matibay na security measures para maprotektahan ang personal information ng bawat tao. Sa ganitong paraan, mas nagiging responsable at mas ligtas ang paggamit ng data mining.

**SLIDE 35:**
**TOPIC:**

**BIG DATA CHALLENGES**

**Volume**

- Terabytes of data require expensive, scalable cloud infrastructure instead of traditional storage.

**Velocity**

- Systems must instantly ingest and process real-time streaming data.

**Variety**

- Frameworks must integrate unstructured formats like text, images, and sensor logs.

**Veracity**

- Data is often messy; cleaning duplicates and errors is the most time-consuming phase.

**Value**

- Organizations struggle to translate sheer data mass into actual, actionable business insights.

**INSIGHTS:**

Last but not the least, ang Big Data Challenges. Kahit napakalaking tulong ng Big Data sa iba't ibang industriya, may mga challenges din na kailangan nating harapin. Ito ay kilala rin bilang 5 Vs of Big Data.

Unang challenge ay ang Volume. Ang Volume ay tumutukoy sa sobrang dami ng data na napo-produce araw-araw. Hindi na lang ito basta gigabytes, kundi umaabot na sa terabytes o kahit petabytes ng data. Dahil dito, hindi na sapat ang ordinaryong storage devices. Kailangan na ng mas scalable at mas malalaking cloud storage systems para ma-store at ma-manage ang lahat ng data nang maayos.

Pangalawa ay ang Velocity. Ang Velocity naman ay tungkol sa bilis ng pagpasok at pag-process ng data. Sa panahon ngayon, tuloy-tuloy ang pag-generate ng data mula sa social media, online transactions, sensors, at iba pang digital platforms. Kaya kailangan ng system na mabilis mag-process ng real-time data para makapagbigay agad ng tamang impormasyon o decision.

Pangatlo ay ang Variety. Ang Variety ay tumutukoy sa iba't ibang uri ng data. Hindi lang numbers o tables ang data ngayon. Kasama na rin dito ang text, images, videos, audio files, at pati sensor logs. Dahil magkakaiba ang format ng mga ito, kailangan ng systems na kayang pagsamahin at i-process ang iba't ibang klase ng data sa iisang platform.

Pang-apat ay ang Veracity. Ang Veracity ay tungkol sa quality o accuracy ng data. Hindi lahat ng nakokolektang data ay malinis o tama. Minsan may duplicate records, missing values, o maling impormasyon. Kaya isa sa pinaka-time-consuming na proseso sa Big Data ay ang data cleaning para masigurong accurate at reliable ang data bago ito gamitin sa analysis.

At ang huli ay ang Value. Kahit napakaraming data ang meron ang isang organization, hindi ibig sabihin ay automatic na magiging useful ito. Ang challenge dito ay kung paano makakakuha ng meaningful insights mula sa data. Ang goal ay gawing useful information ang raw data para makatulong sa paggawa ng better decisions at mas mapabuti ang operations ng isang organization.

So, overall, ito ang limang pangunahing challenges ng Big Data: Volume, Velocity, Variety, Veracity, at Value. Mahalaga na ma-address ang bawat isa sa mga ito dahil kahit gaano karami ang data na meron tayo, magiging kapaki-pakinabang lang ito kung maayos itong ma-store, ma-process, malinis, at magagamit sa paggawa ng tamang desisyon.